⟨로지스틱⟩

① Probit vs logit ⇒ 두개를 fit시키면서, 공부해보기

② $\Phi(\beta_0+\beta_1 x)$

③ MLE(최대우도추정법)

⇒ $\prod_{i=1}^{n}(p_i)(1-p_i)$

⟨복습⟩

모델 ⤳ $y = X\beta+\varepsilon$ (이게 모델이고)

$\hat{y} = X\hat{\beta}$ (적합된 회귀모델)

if and only if

⇒ 필요충분

$\varepsilon_i = y_i - X\beta$ (residual = 잔차)

$e_i = \hat{y}_i - X\hat{\beta}$

$\varepsilon_i = \hat{e}_i$

· Least square

⇒ 모든 점을 고려 ... 평면에서 직교의 거리를 minimize

· reduce model과 full model

$$F = \frac{\frac{SSE_R - SSE_F}{df_R - df_F}}{SSE_F/df_F}$$

linear한

R^n 차원의 평면을 그린다.

feature가 많아지면 linear 해지나(?)

· $\hat{\beta} = (X^TX)^{-1}X^TY$

이때 X^TX가 작아지면, $(X^TX)^{-1}$는 커진다.

A = QR 분해

$Q^T = Q^{-1}$ 이라고 가정

가령 $Ax = b$에서

$QRx = b$

$Rx = Q^{-1}b$

$= Q^Tb$

· $X'X = P\Lambda P'$으로 가능

· $\hat{\beta} \geq \hat{\beta}_R$ (Ordinary least square보다, Ridge regression에서 β가 더 작음)

$Z = XP$, $\alpha = P'\beta$로 두자

L_2 norm ⇒ $\|X-X_0\|^2$

L_1 norm ⇒ $|X-X_0|$

⇒ $Y = X\beta+\varepsilon$ (모델)

$= XPP'\beta+\varepsilon$

$= Z\alpha+\varepsilon$ ∴ $Z'Z = P'X'XP = P'P\Lambda P'P$

$= \Lambda$

$\hat{\alpha}$에 대한 회귀 제곱추정량 .... $\hat{\alpha} = (Z'Z)^{-1}Z'Y$

$= \Lambda^{-1}Z'Y$

ridge ⤳ 회귀 시작하기 ⤳ PPT로 보고 복습하기

Lasso ⤳

$\boxed{b_\lambda = (X'X+\lambda I)^{-1}X'Y}$